

1 Détection

À l'instar de la commande `file` d'UNIX, écrivez en C++ un programme qui prend en paramètre une liste de fichiers, et qui écrit, pour chaque fichier, son encodage.

Nous nous limiterons aux encodages suivants :

- ASCII
- ISO 8859-1 (latin-1)
- UTF-8

Afin de faciliter le traitement, nous partons du principe que les fichiers donnés en entrée sont forcément des fichiers textuels, avec l'un de ces encodages.

```
user@host:~$ ./file.out text.*
text.ascii.txt : ASCII
text.latin1.txt : latin-1
text.multi.txt : latin-1
text.utf8-2.txt : UTF-8
text.utf8-3.txt : UTF-8
text.utf8-4.txt : UTF-8
```

FIGURE 1 – Exemple d'utilisation sur des fichiers ASCII, ISO 8859-1 et UTF-8 encodés sur 2, 3 et 4 octets.

La Figure 1 illustre un fonctionnement normal de la commande. Les fichiers utilisés dans l'exemple sont disponibles sur Moodle.

Dans le cas où le fichier n'est pas un fichier texte, ou qu'il n'a pas l'encodage parmi les 3 supportés, il ne vous ait pas demandé d'afficher une erreur.

```
user@host:~$ ./file.out file.out
file.out : latin-1
```

FIGURE 2 – Exemple d'utilisation sur un fichier binaire.

La Figure 2 illustre l'utilisation de la commande sur un fichier binaire. Ici l'encodage détecté est indiqué « latin-1 » mais un autre encodage aurait pu être affiché.

Rappels pour détecter un encodage :

- Si pas de caractères spéciaux : ASCII
- Si on détecte un caractère sur 2, 3 ou 4 octets : UTF-8
- Sinon, c'est du latin-1

Pour être considéré comme ASCII, l'ensemble des caractères doit être encodé en ASCII. De même, pour être considéré comme UTF-8, l'ensemble des caractères doit être encodé en UTF-8. Pour être considéré comme latin-1, il suffit qu'un seul caractère soit encodé en latin-1 pour être considéré comme latin-1. Le fichier `text.multi.txt` de la Figure 1 illustre ce mécanisme.

2 Conversion

À l'instar de la commande `iconv` d'UNIX, écrivez en C++ un programme qui prend en paramètre un encodage d'entrée, un encodage de sortie et un nom de fichier. Votre programme devra écrire sur la sortie standard l'équivalent du texte contenu dans le fichier, traduit de l'encodage d'entrée vers l'encodage de sortie.

```
user@host:~$ cat text.latin1.txt
?a c'est du latin1.
user@host:~$ ./iconv.out latin1 utf8 text.latin1.txt
Ça c'est du latin1.
user@host:~$ ./iconv.out latin1 utf8 text.utf8-2.txt
Ceci est un texte Ã©crit en UTF8.
user@host:~$ ./iconv.out utf8 latin1 text.latin1.txt
? c'est du latin1.
```

FIGURE 3 – Exemples d'utilisations normales et anormales de `iconv.out` dans une console UTF-8.

La Figure 3 illustre plusieurs utilisations de la commande dans une console en UTF-8 :

- Une conversion de latin-1 vers UTF-8 d'un texte en latin-1 (utilisation normale)
- Une conversion de latin-1 vers UTF-8 d'un texte en UTF-8 (utilisation anormale)
- Une conversion d'UTF-8 vers latin-1 d'un texte en latin-1 (utilisation anormale)

La Figure 4 illustre les utilisations normales de la commande dans une console UTF-8.

```
user@host:~$ ./iconv.out utf8 utf8 text.utf8-2.txt
Ceci est un texte écrit en UTF8.
user@host:~$ ./iconv.out utf8 latin1 text.utf8-2.txt
Ceci est un texte ?crit en UTF8.
user@host:~$ ./iconv.out latin1 latin1 text.latin1.txt
?a c'est du latin1.
user@host:~$ ./iconv.out latin1 utf8 text.latin1.txt
Ça c'est du latin1.
```

FIGURE 4 – Exemples d'utilisations normales de `iconv.out` dans une console UTF-8.

On pourra vérifier la bonne traduction avec la commande de détection d'encodage, comme illustré sur la Figure 5.

```
user@host:~$ ./iconv.out utf8 latin1 text.utf8-2.txt > output.latin1.txt
user@host:~$ ./iconv.out latin1 utf8 text.latin1.txt > output.utf8.txt
user@host:~$ ./file.out output.*
output.latin1.txt : latin-1
output.utf8.txt : UTF-8
```

FIGURE 5 – Exemples d'utilisations normales de `iconv.out` dans une console UTF-8.