

1 BASH - Fusion de documents

Le but de cet exercice est de rédiger un script BASH qui permet de fusionner des données issues de plusieurs sources.

Tous les documents en entrée sont des fichiers CSV qui contiennent le nom, prénom et l'âge d'individus. Les sources qui ont permis d'obtenir ces informations ont chacune un encodage et un format CSV différent. Pour simplifier, nous partirons du principe que l'encodage des fichiers est soit UTF-8, soit latin-1 ; et le format CSV utilise soit la virgule, soit le point-virgule.

Le script doit fusionner l'ensemble des données d'entrée en UTF-8, et au format CSV utilisant la virgule comme séparateur de champs.

Le premier argument du script doit être le nom du fichier à produire, les autres sont les fichiers d'entrée.

La Figure 1 illustre l'utilisation de la commande avec les fichiers présents sur Moodle.

```
user@host:~$ ./fusion.sh fusion.csv data*
user@host:~$ cat fusion.csv
Prénom,Nom,Âge
Martial,Vasseur,23
Renaud,Rapace,34
Michaël,Droz,36
Noël,Fétique,31
Grégoire,Bruneau,10
Gaétan,Botrel,20
Boniface,Plantier,43
Lionel,Longchambon,25
Jean-Loup,Ballesdens,5
Frédéric,Camille,16
Franck,Alméras,36
Ludovic,Vandame,48
Estienne,Bruneau,52
Quentin,Bocuse,36
Thierry,Chausson,13
Jérémy,Dembélé,25
Lucrèce,Vernier,53
Amaury,Chaney,63
Aubin,Carpentier,75
Hugo,Calvet,98
Égide,Celice,3
Pierre-Antoine,Chapelle,33
Éric,Gavreau,52
Alceste,Crépin,46
Abel,Popelin,28
Arnaud,Chausson,45
Thibaud,Balzac,32
```

FIGURE 1 – Exemple d'utilisation.

2 AWK

2.1 Fonctions et Chaînes

Réalisez un script AWK qui, à partir d'une liste de prénoms et de noms formate la sortie tel que suit :

- Les prénoms ont tous l'initiale en majuscule et le reste du mot en minuscules (même si le prénom est composé)
- Les noms sont en majuscules
- Les lignes vides doivent être supprimées (ne pas apparaître dans la sortie)

Pour simplifier, vous ferez une première version du script qui n'utilise qu'une liste composée d'un seul prénom et d'un seul nom par individu (fichier `noms_prenoms1.txt`). La première version ne fera que transformer le nom de famille en majuscules.

La Figure 2 illustre le résultat attendu du script avec le fichier `noms_prenoms1.txt`, ainsi que, pour information, sur les trois fichiers `noms_prenoms`.

```
user@host:~$ gawk -f tri1.awk noms_prenoms1.txt
Dany GAUBERT
Cédric THÉVENET
Noëlle BRUNELLE
Clélie BEAUVAU
jean-noël BOISSIEU
Jean-Philippe BASSOT
user@host:~$ # POUR INFORMATION
user@host:~$ gawk -f tri1.awk noms_prenoms*
Dany GAUBERT
Cédric THÉVENET
Noëlle BRUNELLE
Clélie BEAUVAU
jean-noël BOISSIEU
Jean-Philippe BASSOT
Édouard PHILIPPE
jean BAPTISTE
DANIEL COHN
Jeanne D'ARC
Valéry GISCARD
Jean DE
JEAN-LUC GODARD
Édouard,PHILIPPE
jean BAPTISTE,POQUELIN
DANIEL,COHN BENDIT
Jeanne,d'Arc
VALÉRY,Giscard D'ESTAING
Jean,de LA
JEAN-LUC,GODARD
```

FIGURE 2 – Exemple d'utilisation de la première version du script.

Essayez de faire un script similaire (uniquement transformer le nom de famille) pour traiter les informations du fichier `noms_prenoms2.txt`. Que remarquez-vous ?

En formatant les fichiers en entrées, il est plus facile de traiter le document. En utilisant le fichier `noms_prenoms3.txt` en entrée, faites une deuxième version du script qui cette fois-ci permet de formater les prénoms et noms tel que souhaité.

Vous ferez attention aux prénoms multiples, ainsi qu'aux prénoms composés. Vous n'afficherez que les lignes non-vides, ainsi que celles qui possèdent le caractère séparateur.

La Figure 3 illustre l'exécution du script sur l'ensemble des fichiers `noms_prenoms`.

```
user@host:~$ gawk -f tri2.awk noms_prenoms*
Édouard PHILIPPE
Jean Baptiste POQUELIN
Daniel COHN BENDIT
Jeanne D'ARC
Valéry GISCARD D'ESTAING
Jean DE LA FONTAINE
Jean-Luc GODARD
```

FIGURE 3 – Exemple d'utilisation de la seconde version du script.

2.2 Gestion des conditions

Écrire un script qui permet de vérifier que les dates de naissances renseignées sont bien formatées (JJ/MM/AA ou JJ/MM/AAAA), avec des valeurs cohérentes pour les jours et pour les mois (on ne vous demande pas de différencier les mois à 29, 30 ou 31 jours).

Une ligne vide sera ignorée. Un avertissement sera affiché lorsqu'une ligne mal formatée est détectée, et la ligne sera ignorée. Les lignes bien formatées devront apparaître dans le fichier `bienFormate.txt`.

Attention, dans le fichier de sortie, toutes les dates sont forcément au format JJ/MM/AAAA. Il faudra donc considérer que toutes les dates de naissances de "01" à "22" (inclus) sont des années 2000, et toutes les autres dates sont des années 1900.


La Figure 4 illustre l'utilisation du script avec le fichier `malFormate.txt` présent sur Moodle.

```
user@host:~$ gawk -f checkAge.awk malFormate.txt
Ligne 11 'Élise,Jeannin,1/02/02' mal formée : ignorée
Ligne 12 'Aurore,Massé,05/12/2015/1' mal formée : ignorée
Ligne 13 'Fanny,Pichard,35/12/90' mal formée : ignorée
user@host:~$ cat bienFormate.txt
Prénom,Nom,Date de Naissance
Ingrid,Saunier,01/02/2003
Claire,Galopin,14/11/1994
Capucine,Dufresne,31/03/2001
Sylvia,Gachet,21/10/1987
Peggy,Houdin,07/09/1995
Jocelyne,Asselineau,09/07/1995
Ève,Aubert,14/07/2021
```

FIGURE 4 – Exemple d'utilisation du script demandé.

2.3 Gestion des variables

Écrire un script qui, à partir d'une sortie de `ls -l`, affiche le nombre de fichiers et le poids total du répertoire, comme illustré par la Figure 5.



```
user@host:~$ ls -l | gawk -f tailleRepertoire.awk
Il y a 18 fichiers pour un total de 85227 octets.
```

FIGURE 5 – Exemple d'utilisation du script demandé.